

UCSC tại SemEval-2025 Nhiệm vụ 3: Bối cảnh, mô hình và tối ưu hóa nhanh chóng để phát hiện ảo giác tự động trong đầu ra LLM

Từ Thông Hoàng
Tân Thành Hà
Thạch Nguyễn Hoàng
Karthik Raja Anandan
Luân xa Arkajyoti
lan ngổ
Đại học California, Santa Cruz
{shuan213, jhe516, shuan101, kanandan, achakr24, ilane}@ucsc.edu

Tóm tắt

Ảo giác đặt ra một thách thức đáng kể cho các mô hình ngôn ngữ lớn khi trả lời các câu hỏi đòi hỏi nhiều kiến thức. Như LLM được chấp nhận rộng rãi hơn, điều quan trọng là không chỉ để phát hiện xem ảo giác có xảy ra hay không mà còn để xác định chính xác vị trí của LLM out-dated chúng xảy ra. SemEval 2025 Nhiệm vụ 3, Mu-SHROOM: Nhiệm vụ chia sẻ đa ngôn ngữ trên Hallucinations và Overgener có thể quan sát được có liên quan. Những sai lầm, là một nỗ lực gần đây theo hướng này chuyên. Bài viết này mô tả hệ thống UCSC nộp nhiệm vụ Mu-SHROOM được chia sẻ. Chúng tôi giới thiệu một khung công tác đầu tiên truy xuất bối cảnh có liên quan, tiếp theo xác định nội dung sai từ câu trả lời và cuối cùng ánh xạ chúng trở lại để kéo dài trong đầu ra LLM. Quá trình này là được tăng cường hơn nữa bằng cách tự động tối ưu hóa lời nhắc. Hệ thống của chúng tôi đạt được hiệu suất cao nhất tất cả hiệu suất, xếp hạng số 1 ở vị trí trung bình trên tất cả các ngôn ngữ. Chúng tôi phát hành mã của mình và kết quả thí nghiệm.¹

¹ Giới thiệu


Ảo giác trong mô hình ngôn ngữ lớn (LLM) kết quả đầu ra vẫn là một mối quan tâm đáng kể (Sahoo et al., 2024; Huang và cộng sự, 2025), làm suy yếu niềm tin của người dùng vào những công việc đòi hỏi nhiều kiến thức. Trong phần trả lời câu hỏi, ảo giác biểu hiện khi mô hình tạo ra sai hoặc thông tin chưa được xác minh dựa trên kiến thức thế giới trong khi vẫn duy trì cấu trúc phản hồi mạch lạc (Mishra và cộng sự, 2024). Trong khi nghiên cứu trước đây đã phát triển các số liệu và điểm chuẩn để phát hiện sự hiện diện của ảo giác-quốc gia (Lin và cộng sự, 2022; Min và cộng sự, 2023), hầu hết các phương pháp tiếp cận chỉ cung cấp đầu ra nhị phân hoặc vô hướng. Những phép đo này, mặc dù có giá trị, đưa ra những hạn chế cái nhìn sâu sắc về các vị trí cụ thể của ảo giác-nội dung được nêu rõ, mặc dù đã bản địa hóa chính xác rất quan trọng cho việc kiểm tra thực tế và cải tiến mô hình.

Nhiệm vụ 3 của SemEval 2025, Mu-SHROOM: Nhiệm vụ chia sẻ đa ngôn ngữ về ảo giác và Những sai lầm quá mức có thể quan sát được có liên quan (Vázquez và cộng sự, 2025), giải quyết khoảng cách này bằng cách kéo dài người tham gia để xác định cả hai khoảng thời gian của văn bản ảo giác và sự tự tin liên quan. Nhiệm vụ bao gồm 14 ngôn ngữ và đánh giá hiệu suất hệ thống trên Intersection-over-Union (IoU) và tương quan chéo (Corr) trên LLM đầu ra có nhãn sự thật cơ bản do con người chú thích. Nhóm UCSC đã tiếp cận thử thách này bằng cách sử dụng một khuôn khổ gồm nhiều bước bao gồm: (i) bối cảnh truy xuất từ các nguồn kiến thức bên ngoài, (ii) giải phát hiện nội dung sai lệch hoặc không thể xác minh và (iii) ánh xạ nội dung lỗi trở lại các khoảng văn bản. bổ sung-Về mặt thực tế, chúng tôi đã khám phá việc sử dụng lời nhắc tự động tối ưu hóa ở bước (ii) và cho thấy thêm điều này hiệu suất hệ thống đã được chứng minh. Đường ống đề xuất căn cứ phản hồi LLM trong bối cảnh được truy xuất để phân biệt nội dung thật với nội dung bịa đặt, trong khi tối ưu hóa nhanh chóng năng cao độ tin cậy phát hiện và độ chính xác ghi nhận nhịp. Hệ thống của chúng tôi xếp hạng cao trong số các ứng dụng được gửi hệ thống, đạt được chiến thắng bằng 5 ngôn ngữ và đứng đầu hai vị trí trong 11 trong số 14 ngôn ngữ trên IoU và 10 trong số 14 ngôn ngữ trên Corr. Sự tham gia của chúng tôi vào Mu-SHROOM tiết lộ một cái nhìn sâu sắc quan trọng: khi kết hợp với "bối cảnh phù hợp", một lời nhắc nhờ đơn giản-phương pháp tiếp cận dựa trên có thể phát hiện ảo giác một cách đáng tin cậy với độ chính xác tốt hơn con người.

² Nền

^{2.1} Công việc liên quan

Những nỗ lực gần đây nhằm vào ảo giác ở cấp độ-phát hiện tion để trả lời câu hỏi, như vậy như HaluQuestQA (Sachdeva và cộng sự, 2024) và RAGTruth (Niu và cộng sự, 2024) cung cấp thông tin chi tiết chú thích của các nhịp ảo giác, cho phép sự phát triển của sàng lọc thông báo lỗi và hệ thống kiểm tra thực tế tăng cường truy xuất. Vì



Hình 1: Khung phát hiện ảo giác của UCSC. Chúng tôi truy xuất ngữ cảnh từ các nguồn bên ngoài, xác định sai nội dung trong câu trả lời, sau đó ánh xạ các lỗi này trở lại các khoảng cụ thể trong đầu ra LLM. Trong cài đặt đa ngôn ngữ, chúng tôi khám phá việc truy xuất ngữ cảnh bằng ngôn ngữ gốc hoặc bằng tiếng Anh bằng cách dịch câu hỏi. Trong mọi trường hợp nội dung ảo giác được tạo ở bước thứ hai vẫn giữ nguyên ngôn ngữ gốc và được ánh xạ tới câu trả lời.

tóm tắt, Chu và cộng sự. (2021) đề xuất mã thông báo-nhiệm vụ dự đoán mức độ ảo giác và giới thiệu một phương pháp học giải quyết nhiệm vụ bằng mô hình tinh chỉnh trên dữ liệu tổng hợp. Marfurt và Henderson (2022) đề xuất phát hiện ảo giác trong thời trang không giám sát từ máy biến áp tự chú ý. Min và cộng sự. (2023) đề xuất phá vỡ thể hệ các phép tính xuống các sự kiện nguyên tử và gán một nh phân gắn nhãn cho từng sự kiện, cho biết tính trung thực của nó. Làm thế nào-bao giờ hết, bắt chấp những tiến bộ này, những tiêu chuẩn gần đây, ví dụ: FaithBench (Bao và cộng sự, 2024) nêu bật những thách thức dai dẳng, vì ngay cả những hệ thống tiên tiến nhất cũng đấu tranh trong việc phát hiện ảo giác một cách đáng tin cậy. các SemEval-2025 Nhiệm vụ 3 (Mu-SHROOM) được xây dựng dựa trên những nỗ lực này bằng cách giới thiệu một nền tảng đa ngôn ngữ, mở rộng điểm chuẩn phát hiện ảo giác mức độ, đẩy nghiên cứu theo hướng chi tiết hơn, đa ngôn ngữ, và bản địa hóa ảo giác nhận biết ngữ cảnh.

2.2
Mô tả nhiệm vụ

Nhiệm vụ Mu-SHROOM nhằm mục đích xác định ảo giác-khoảng thời gian được nêu trong các câu trả lời do LLM tạo ra trên 14 ngôn ngữ. Người chú thích con người cung cấp sự thật cơ bản nhân: một span là nhận mềm nếu có ít nhất một an-người ghi chú đánh dấu nó là ảo giác và dán nhãn cứng nếu hơn một nửa làm. Người tham gia phải dự đoán cả nhãn mềm và nhãn cứng. Nhãn cứng là được đánh giá bằng cách sử dụng Giao điểm cấp độ ký tự Số liên kết (IoU), trong khi nhãn mềm được đánh giá sử dụng tương quan Spearman (Corr).

3
Tổng quan về hệ thống

Hệ thống chính của chúng tôi áp dụng quy trình ba giai đoạn (xem Hình 1), bao gồm truy xuất bối cảnh, ảo giác phát hiện nội dung cụ thể và ánh xạ nhíp. Bắt đầu quy trình ba giai đoạn, chúng tôi sử dụng phương án nhanh chóng thời gian hóa để tự động tìm kiếm tối ưu nhắc thực hiện phát hiện nội dung ảo giác. Ngoài ra, chúng tôi cũng khám phá một hệ thống kết hợp kỹ thuật tion trong đó chúng tôi coi mỗi hệ thống là một người gắn nhãn riêng lẻ và tổng hợp các kết quả cùng nhau để tăng thêm hiệu suất hệ thống.

3.1
Truy xuất ngữ cảnh

Thế hệ tăng cường truy xuất (RAG) (Lewis et al., 2020) đã được chứng minh là có hiệu quả trong việc giảm ảo giác ở các nhiệm vụ đòi hỏi nhiều kiến thức (Jiang và cộng sự, 2023; Gao và cộng sự, 2024). Chúng tôi cho rằng nó bình đẳng rất quan trọng để bao gồm bối cảnh có liên quan khi xác minh văn bản được tạo ra. Bước một trong quy trình của chúng tôi là thu thập thông tin sẽ hữu ích cho một trong hai câu trả lời-vào câu hỏi đầu vào hoặc khi xác nhận hoặc bác bỏ khẳng định trong câu trả lời đã cho.

Bối cảnh từ câu hỏi Ở đây chúng tôi sử dụng câu hỏi-trực tiếp như truy vấn tìm kiếm được thông qua tới API tìm kiếm bên ngoài. Nội dung trả về là được sử dụng làm bối cảnh. Chúng tôi giả định rằng số tiền được trả lại nội dung sẽ chứa tất cả thông tin cần thiết để trả lời câu hỏi đầu vào và như vậy là đủ có thể xác minh một câu trả lời khác cho cùng một câu hỏi.

Bối cảnh từ yêu cầu bồi thường
Trong cách tiếp cận này, chúng tôi
câu trúc một tập hợp các truy vấn từ các yêu cầu trọng câu trả lời.
Bối cảnh kết quả sau đó có thể được sử dụng để kiểm tra thực tế
tất cả các khẳng định trong câu trả lời, không chỉ những khẳng định
trực tiếp
liên quan đến câu hỏi. Phương pháp này sẽ giúp xác minh
những tuyên bố trong câu trả lời còn thiếu trong câu hỏi
văn bản thu được từ việc truy vấn API tìm kiếm chỉ bằng
câu hỏi.

3.2
Phát hiện nội dung ảo giác

Ở bước hai, chúng tôi xác định nội dung trong câu trả lời
có thể được xác định bởi bối cảnh được truy xuất. Ở đây
chúng tôi so sánh
ba triển khai riêng biệt.

Trích xuất văn bản trực tiếp
Chúng tôi nhắc LLM
phân tích văn bản trả lời và xác định các phân đoạn cụ thể
các nội dung không thể xác minh được từ ngữ cảnh được truy xuất.
các
LLM so sánh văn bản trong câu trả lời với nội dung
văn bản, trích xuất bất kỳ khoảng văn bản nào có chứa thông tin
thiếu vắng hoặc mâu thuẫn với bối cảnh.

Xác minh bằng Sơ đồ tri thức
Trong ứng dụng này-
proach bối cảnh được phân tích cú pháp thành một biểu đồ tri
thức
bao gồm các thực thể và quan hệ, trong khi câu trả lời
được phân rã thành các sự kiện riêng lẻ. LLM là
sau đó được sử dụng để xác minh từng sự kiện bằng cách
truy vấn thông tin
về các thực thể, kiểm tra độ chính xác đối với
đồ thị kiến thức. Phương pháp này đảm bảo mỗi
thực thể được xác minh chéo với dữ liệu có cấu trúc, với
mục tiêu nâng cao độ tin cậy của ảo giác
quá trình phát hiện.

Sửa đổi chi phí tối thiểu
Trong cách tiếp cận này, chúng tôi sử dụng
một LLM lý luận để sửa câu trả lời được cung cấp bởi
thực hiện ít thay đổi nhất có thể. Phương pháp này
đảm bảo rằng việc sửa chữa chỉ giới hạn ở
những phần cần thiết của văn bản, với những khác biệt
giữa câu trả lời ban đầu và câu trả lời đã được sửa
cho là bị ảo giác.

3.3
Ảnh xạ nhíp

Sau khi xác định được nội dung gây ảo giác trong
câu trả lời, chúng tôi chuyển đổi các phân khúc rộng này
thành
kéo dài cấp độ kỹ tự. Việc chuyển đổi này sử dụng ba
các phương pháp cụ thể, mỗi phương pháp tương ứng với
một trong các
ba kỹ thuật phát hiện nội dung ảo giác:

Kết hợp chuỗi con
Khớp chuỗi con chính xác với lo-
chỉ ra những khoảng ảo giác trong câu trả lời. Cái này
Cách tiếp cận được sử dụng với việc trích xuất văn bản trực
tiếp trong bước
2, trong đó các đoạn văn bản cụ thể được xác định là
bị ảo giác.

Lập bản đồ thực tế theo khoảng cách
Chúng tôi nhắc LLM để
ánh xạ các sự kiện sai đã được xác định trở lại cụ thể
các đoạn văn bản trả lời đã tạo ra những dữ kiện đó.
Phương pháp này được áp dụng sau khi xác minh bằng
đồ thị tri thức ở bước 2, đảm bảo rằng mỗi sai
thực tế được truy tìm chính xác đến văn bản nguồn của nó.

Lập bản đồ thông qua chỉnh sửa khoảng cách
Tính toán nhỏ
mẹ chỉnh sửa khoảng cách cần thiết để chuyển đổi nguồn
gốc
câu trả lời cuối cùng vào phiên bản sửa chữa. Trong thời gian
này
quá trình, tất cả việc xóa và thay thế các từ
được xác định, với những từ này được dán nhãn là
ảo giác. Phương pháp này đảm bảo độ chính xác
xác định thông tin không cần thiết hoặc không chính xác
ngữ trong văn bản.

3.4
Tối ưu hóa nhanh chóng với MiPROv2

Để tinh chỉnh bước phát hiện nội dung ảo giác,
chúng tôi đã sử dụng MiPROv2 (Opsahl-Ong và cộng sự,
2024),
một khuôn khổ có hệ thống để tối ưu hóa các lời nhắc trong
chương trình mô hình ngôn ngữ. Đòn bẩy MiPROv2
Tìm kiếm Bayes để khám phá lời nhắc ứng viên
tối ưu hóa số liệu nhiệm vụ (ví dụ: IoU hoặc Corr). Trong mỗi
lập đi lặp lại, MiPROv2 đề xuất các bản cập nhật cho cả
hướng dẫn và trình diễn vài lần bản, đánh giá
chúng trên một tập hợp con dữ liệu và sử dụng những kết
quả đó để
hướng dẫn vòng đề xuất tiếp theo. Quá trình này
phát hiện một cách có hệ thống những gợi ý mang lại hiệu
quả mạnh mẽ
hiệu suất, nâng cao độ tin cậy của bước 2.

3.5
Hệ thống đa ngôn ngữ

Thiết kế khung của chúng tôi được thúc đẩy bởi
giả định rằng các LLM được đào tạo trước mà chúng tôi đã
sử dụng
có thể hoạt động tốt hơn bằng tiếng Anh, do có nhiều
điều nhảy của dữ liệu đào tạo tiếng Anh
nói chung có sẵn. Để phát hiện ảo giác
việc sử dụng văn bản không phải tiếng Anh được sử dụng
chính xác theo cùng một phương pháp-
od như đã mô tả ở trên. Tuy nhiên chúng tôi đã khám phá
một biến thể cụ thể: chúng tôi đã so sánh việc sử dụng En-
bối cảnh hào nhoáng so với ngôn ngữ đích (tức là không phải
tiếng Anh)
bối cảnh cho 13 ngôn ngữ khác trong Mu-
nhiệm vụ SHROOM.
Bối cảnh tiếng Anh
thu được bằng cách dịch các câu hỏi đã cho hoặc
yêu cầu sang tiếng Anh trước khi truy xuất. Đối với mục tiêu-
bối cảnh ngôn ngữ chúng tôi sử dụng câu hỏi hoặc khẳng
định
bằng ngôn ngữ gốc để truy xuất thông tin cần thiết
văn bản. Trong cả hai trường hợp này, nội dung không thể
xác minh được
được dán nhãn bằng ngôn ngữ gốc và sau đó được ánh xạ
quay lại câu trả lời.

	IOU
Kết hợp đa hệ thống 0,65 0,69 0,53 0,63 0,58 0,44 0,59 0,63 0,65 0,57 0,71 0,76 0,65 0,46	
	Corr
Kết hợp đa hệ thống 0,65 0,79 0,58 0,66 0,65 0,63 0,62 0,67 0,65 0,60 0,76 0,79 0,53 0,43	

Bảng 1: Kết quả kiểm tra IoU và Corr đa ngôn ngữ. Chọn, chỉ ra rằng tối ưu hóa nhanh chóng đã được thực hiện và Trans. cho biết liệu đầu vào có được dịch sang tiếng Anh hay không trước khi thực hiện truy xuất ngữ cảnh. Tất cả các bối cảnh đều có nguồn gốc từ Sonar bởi rỗi Pro. IoU được sử dụng làm thước đo tối ưu hóa nhanh chóng cho tất cả các ngôn ngữ ngoại trừ tiếng Anh, trong đó Corr đã được áp dụng. Chúng tôi nhấn mạnh hệ thống riêng lẻ hoạt động tốt nhất và in đậm hệ thống tốt nhất về tổng thể.

3.6
Kết hợp nhiều hệ thống

Trọng tâm của chúng tôi trong công việc này là tạo ra sự chăm chỉ nhân cho các phân đoạn bị ảo giác với mục tiêu tối đa hóa điểm IoU. Chúng tôi tin rằng cách tiếp cận này là tốt nhất nếu mục tiêu là cung cấp phản hồi rõ ràng cho người sử dụng các hệ thống như vậy. Ví dụ khi chúng ta muốn để làm nổi bật những phân đoạn nào trong đầu ra LLM có thể sai hoặc không thực tế. Khi xem xét xác suất của một mã thông báo cụ thể trong LLM đầu ra có phải là ảo giác hay không, các phương pháp trước đó phần lớn dựa vào chính mô hình ngôn ngữ để tạo ra đã ăn "khả năng đạt được điểm chính xác." Điểm số như vậy được cho là luôn luôn ở mức quá cao, vì các mô hình quá tự tin vào sản phẩm của mình. Ngoài ra, điểm số thu được không phù hợp lắm với độ xác định định nghĩa của nhân mềm trong tác vụ Mu-SHROOM, tức là nhân dựa trên tỷ lệ người chú thích đồng ý về việc liệu một số nhịp nhất định có bị ảo giác hay không. Trong nhiệm vụ thử thách Mu-SHROOM, chúng tôi bị cám dỗ để tái tạo quá trình dán nhãn của con người bằng cách có nhiều hệ thống khác nhau xuất ra cứng-nhân. Sau đó chúng tôi kết hợp các bộ nhân cứng này để tạo ra các nhân mềm dựa trên thỏa thuận nhân. Kỳ vọng là giống như những người chú thích của con người, hệ thống các tem sẽ khác nhau về loại mã thông báo cụ thể mà chúng gắn nhãn ở đầu ra LLM. Để kết hợp hệ thống trong của chúng tôi hệ thống gửi, chúng tôi đã kết hợp đầu ra của năm hệ thống khác nhau cùng nhau. Bằng cách xử lý từng hệ thống với tư cách là người chú thích, chúng tôi tính toán tỷ lệ của các hệ thống dán nhãn một khoảng thời gian cụ thể là ảo giác nated.

4
Thiết lập thử nghiệm

4.1
Mô hình và Công cụ

Để truy xuất ngữ cảnh, chúng tôi sử dụng mô hình sonar-pro thông qua Perplexity API2 (có thể tìm thêm thông tin chi tiết trong Phụ lục C). Để phát hiện ảo giác nội dung, chúng tôi thường sử dụng GPT-4o của OpenAI và GPT-4o-mini (OpenAI và cộng sự, 2024). Đối với nhiệm vụ của sửa câu trả lời với những thay đổi tối thiểu, tức là Min-Sửa đổi chỉ phí imal như được mô tả trong phần 3.2, chúng tôi nhận thấy rằng mô hình lý luận OpenAI o1 (OpenAI, 2024) hoạt động tốt hơn các mẫu GPT-4. cho các hệ thống đa ngôn ngữ, chúng tôi cũng đánh giá hiệu suất của DeepSeek-R1 (DeepSeek-AI và cộng sự, 2025) và khi thực hiện kết hợp hệ thống, chúng tôi cũng bao gồm Llama3.3-70B (Grattafiori và cộng sự, 2024) là một trong 5 hệ thống được kết hợp. Chúng tôi đã sử dụng LangChain3 để xây dựng quy trình cho hệ thống gửi của chúng tôi và cũng để xây dựng đồ thị tri thức4 được sử dụng để xác minh với Sơ đồ tri thức + phương pháp ánh xạ thực tế theo khoảng thời gian. DSPy (Khattab và cộng sự, 2024) được sử dụng để thực hiện tối ưu hóa nhanh chóng. Khi thực hiện nhắc nhở tối ưu hóa trên bộ xác thực mà chúng tôi thực hiện 2-gấp xác nhận chéo để đảm bảo độ tin cậy.

2<https://sonar.perplexity.ai>
3<https://langchain.com>
4https://python.langchain.com/docs/how_to/graph_xây_dựng/

Xếp hạng loU trung bình: 2,6; Xếp hạng Corr trung bình: 2,4

Bảng 2: Hệ thống xếp hạng trên tất cả các ngôn ngữ.

	loU Corr	loU Corr
Từ Q	Văn bản Extr.+ Substr. Trần đầu 0,55 0,46 0,56 0,52 KG Verif.+ Facto-Span 0,23 0,24 0,22 0,19 Revi.+ Chi phí tối thiểu Chính sửa Dist. 0,52 0,40 0,53 0,49	
Từ C	Văn bản Extr.+ Substr. Trần đầu 0,46 0,48 0,55 0,53 KG Verif.+ Facto-Span 0,22 0,24 0,20 0,14 Revi.+ Chi phí tối thiểu Chính sửa Dist. 0,55 0,46 0,53 0,49	

Bảng 3: Kết quả tiếng Anh của các luồng hệ thống khác nhau.
Trích xuất văn bản và sử dụng xác minh biểu đồ tri thức
gpt-4o-mini và bản sửa đổi chi phí tối thiểu sử dụng o1.

4.2 Chú thích và số liệu thay thế

Để hiểu rõ hơn những thách thức của ảo giác- nhiệm vụ gắn nhãn phạm vi quốc gia, chúng tôi đã gắn nhãn theo cách thủ công Xác nhận người Anh do chính chúng tôi đặt ra. Khi chúng tôi đánh giá- đã chỉnh sửa các chú thích nội bộ của chúng tôi dựa trên phản ứng và chú thích mềm do ban tổ chức cung cấp, chúng tôi thấy rằng IoU trung bình của chúng tôi là 0,43 và Erage Corr là 0,40. Chúng tôi thích tốt nhất trong nhóm đạt được IoU là 0,48 và Corr là 0,48 và người chủ thích có điểm thấp nhất đạt được IoU là 0,37 và Corr hoặc 0,34. Chúng tôi tìm thấy điều đó ngay cả người chủ thích cá nhân giỏi nhất của chúng tôi cũng thực hiện dấu hiệu tệ hơn nhiều so với tất cả các hệ thống dựa trên LLM của chúng tôi.

Để so sánh hệ thống hoạt động tốt nhất của chúng tôi trên bộ xác thực thủ được IoU là 0,57 và Corr là 0,55. Chúng tôi đưa ra giả thuyết rằng hai yếu tố hạn chế sự trùng lặp của chúng tôi với sự thật cơ bản: (i) thiếu chính xác bối cảnh tham khảo, dẫn đến sự khác biệt trong ver- hóa và (ii) những khác biệt tiềm ẩn trong việc ghi nhãn hướng dẫn.

Do sự thỏa thuận thấp giữa nội bộ của chúng tôi người chủ thích, đề hướng dẫn phát triển hệ thống tốt hơn, chúng tôi đã giới thiệu số liệu mới MaxIoU, lấy cảm hứng từ chỉ số Jaccard trung bình tối đa (Cronin và cộng sự, 2017). MaxIoU giảm thiểu sự mâu thuẫn trong việc ghi nhãn của con người- xu hướng bằng cách xác định IoU bằng một an- ký hiệu cung cấp IoU cao nhất, thay vì tổng hợp kết quả thành nhãn mềm hoặc cứng. các chỉ tiết về số liệu được cung cấp trong phụ lục A.

chứng minh tính hiệu quả và tính tổng quát của cách tiếp cận của chúng tôi.

Kết quả đa ngôn ngữ của chúng tôi được trình bày trong Bảng 1.

Trong số các kết quả của một hệ thống không có sự tối ưu hóa kịp thời

hóa hoặc dịch thuật, DeepSeek-R1 thực hiện tốt nhất xét về cả IoU (0,59) và Corr (0,60).

Tuy nhiên, khi có sự tối ưu hóa kịp thời, GPT-4o trở thành mẫu tốt nhất về tổng thể, mặc dù không phải tất cả các ngôn ngữ đều được hưởng lợi từ việc tối ưu hóa nhanh chóng.

Bảng 1 cũng so sánh hiệu quả của việc dịch thuật ngữ câu hỏi sang tiếng Anh trước khi tra cứu và kết quả cho biết nó làm giảm hiệu suất một chút: từ 0,58 đến 0,56 IoU và từ 0,54 đến 0,53 Corr.

Bảng 1 còn bao gồm các sản phẩm có hiệu suất tốt nhất

hệ thống được kết hợp từ một tập hợp đa dạng các hệ thống riêng lẻ

tems. Sự kết hợp hệ thống cải thiện điểm Corr, trung bình là 5% (từ 0% đến 12% trên toàn 14 ngôn ngữ) nhưng nhìn chung cũng phải chịu -5% suy thoái (từ 0% đến -16% trong 14 ngôn ngữ) ở IoU.

5.2 Phân tích kết quả

Luồng hệ thống
Bảng 3 so sánh hiệu suất
cho các luồng hệ thống khác nhau. Chúng tôi thấy rằng bao
gồm
bối cảnh được truy xuất sẽ tăng hiệu suất bằng cách xem xét
lề có thể xóa được. Tăng IoU thêm 27% từ 0,44
xuống 0,56 và Corr giảm 23% từ 0,43 xuống 0,53. Cre-
hiệu ngữ cảnh từ các câu hỏi hoạt động tốt hơn một chút
hơn là tạo từ các xác nhận quyền sở hữu theo IoU cho văn
bản
trích xuất và xác minh biểu đồ tri thức, nhưng
để sửa đổi với chi phí tối thiểu, tạo bối cảnh từ
khiến nại có hiệu quả hơn. Chúng tôi nghi ngờ rằng nguyên
nhân
con trai là mô hình o1 có thể tận dụng tốt hơn
thông tin kiểm tra thực tế vì lý do của nó
khả năng. Phương pháp dựa trên đồ thị tri thức cho mỗi
hình thức tôi tệ hơn đáng kể so với các phương pháp khác,
với IoU và Corr đạt xấp xỉ 1/2
của các phương pháp khác. Khi kiểm tra thủ công,

5 Kết quả & Phân tích

5.1 Kết quả chính

Trên 43 nhóm tham gia, hệ thống UCSC luôn đạt được hiệu suất mạnh mẽ trên tất cả các hầu hết tất cả các ngôn ngữ. Bảng 2 cho thấy thứ hạng hệ thống của chúng tôi ở hai vị trí hàng đầu trong 11 trong số 14 ngôn ngữ trên loU và 10 trong số 14 ngôn ngữ trên Corr. Long-termore, chúng tôi xếp hạng cao nhất ở vị trí trung bình trên tất cả 14 ngôn ngữ. Khi hệ thống của chúng tôi phát triển—ment chỉ tập trung vào tiếng Anh, những kết quả này

	IoU	Corr	IoU	Corr
□	0,44	0,51	0,55	0,51
IoU	0,57	0,55	0,60	0,55
Corr	0,54	0,54	0,61	0,55
MaxIoU	0,55	0,57	0,60	0,55
IoU + Corr	0,53	0,56	0,57	0,53

Bảng 4: Kết quả tiếng Anh của GPT-4o về trích xuất văn bản đường dẫn với các mục tiêu tối ưu hóa nhanh chóng khác nhau.

chúng tôi đã tìm thấy bước xác minh biểu đồ tri thức có thể xác định một cách hợp lý các sự kiện sai bằng cách truy vấn đồ thị tri thức, nhưng ánh xạ thực tế theo khoảng thời gian là cũ cực kỳ không đáng tin cậy, dẫn đến một lượng lớn tiếng ồn trong các nhịp được dán nhãn. Điều này dẫn đến đáng kể hiệu suất tổng thể của hệ thống thấp hơn. Chi phí tối thiểu sửa đổi nổi bật như một cách tiếp cận cạnh tranh, tất cả mặc dù nó có khả năng tính toán cao hơn đáng kể chi phí do yêu cầu lý luận trong quá trình suy luận.

Tối ưu hóa nhanh chóng
Bảng 4 cho thấy hiệu suất hiệu suất của GPT-4o với các tính năng tối ưu hóa nhanh chóng khác nhau- mục tiêu hoạt động. Hiệu suất đạt được từ lời nhắc tối ưu hóa là rõ ràng. Tuy nhiên, không có một lựa chọn duy nhất nào mục tiêu thu nhỏ luôn vượt trội so với các mục tiêu khác trên cả bộ xác nhận và bộ kiểm tra. Đây là có thể là do chúng ta sử dụng cùng một mô hình nhắc nhở để xuất lời nhắc, mặc dù đã tối ưu hóa các cách khác nhau mục tiêu.

Kết hợp hệ thống
Như đã thảo luận ở phần 3.6, chúng ta đã khám phá việc kết hợp các dự đoán từ nhiều hệ thống nhằm cải thiện điểm tương quan. Chúng tôi cẩn thận đã lựa chọn một nhóm các mô hình có hiệu suất cao khác nhau về kiến trúc, xử lý bối cảnh và tối ưu hóa chiến lược tối ưu hóa. Chúng tôi thấy rằng hệ thống combination cải thiện điểm Corr, trung bình 5% (từ 0% đến 12% trên 14 ngôn ngữ) nhưng nó thường phải chịu sự xuống cấp -5% (giữa 0% và -16% trên 14 ngôn ngữ) trong IoU. De-đuôi của các hệ thống kết hợp đa ngôn ngữ, trong bao gồm các cấu hình và phương pháp của chúng, là được cung cấp trong Phụ lục B.

Mặc dù đạt được thành tích đáng chú ý, một số tồn tại những hạn chế. Hệ thống hoạt động kém hiệu quả trong Tiếng Trung, có thể là do độ phức tạp cao của Chi-bộ dữ liệu nese và sự quen thuộc hạn chế của các mô hình với kiến thức này bằng tiếng Trung. Khi kiểm tra hệ thống, chúng tôi thấy rằng nó hoạt động tốt trong điều kiện truy xuất văn bản và phát hiện nội dung ảo giác, đặc biệt thông qua việc xác minh biểu đồ tri thức-cách tiếp cận. Điều này phù hợp với những quan sát về sự không nhất quán trong việc dán nhãn cho con người. Hơn nữa, hệ thống của chúng tôi phụ thuộc rất nhiều vào bối cảnh và khả năng ghi nhận tổng quát của LM. Đạt được hiệu suất cực cao của hệ thống hoạt động tốt nhất trong bài viết này có thể không chỉ phí hiệu quả trong trường hợp sử dụng thực tế.

Trong bài viết này, chúng tôi đã mô tả kiến trúc hệ thống của mình, hệ thống thăm dò và đệ trình lên SemEval Nhiệm vụ 2025 3 (Mu-SHROOM) cho hal- đa ngôn ngữ ghi nhận khoảng sáng chói trong đầu ra LLM. đa của chúng tôi khung giai đoạn, kết hợp truy xuất ngữ cảnh, phát hiện ảo giác và lập bản đồ nhịp với tối ưu hóa nhanh chóng, đạt được hiệu suất mạnh mẽ, xếp ở hai vị trí hàng đầu ở 11 trên 14 ngôn ngữ trong bộ đánh giá. Thông qua công việc của chúng tôi, chúng tôi phát hiện ra rằng (i) truy xuất bối cảnh có liên quan là rất quan trọng để phát hiện ảo giác, (ii) đơn giản trích xuất văn bản thường hoạt động tốt hơn phức tạp hơn các phương pháp tiếp cận và (iii) tối ưu hóa nhanh chóng cải thiện hiệu suất hệ thống. Hơn nữa, chúng tôi thấy có ý nghĩa sự khác biệt trong các khoảng chú thích giữa con người và người ký hiệu, ngay cả khi đồng ý về các sự kiện cơ bản, gợi ý rằng một khuôn khổ được xác định rõ ràng hơn cho chú thích có thể mang lại lợi ích cho cả tự động và con người dán nhãn cho các nhịp ảo giác.

Forrest Sheng Bao, Miaoran Li, Renyi Qu, Ge Luo, Erana Wan, Yujia Tang, Weisi Fan, Manveer Singh Tamber, Suleman Kazi, Vivek Sourabh, Mike Qi, Ruixuan Tu, Chenyu Xu, Matthew Gonzales, Ofer Mendelevitch và Amin Ahmad. 2024. Bàn thờ đức tin: Một chuẩn mực ảo giác đa dạng đề tóm tắt-tion của llms hiện đại. Bản in trước, arXiv:2410.13210.

Robert M Cronin, Daniel Fabbri, Joshua C Denny, S Trent Rosenbloom và Gretchen Purcell Jackson. 2017. So sánh giữa học máy và dựa trên quy tắc-các phương pháp phân loại thông tin công thông tin bệnh nhân. Tạp chí quốc tế về tin học y tế, 105: 110–120.

DeepSeek-AI, Daya Guo, Dejian Yang, Haowei Zhang, Bài hát Junxiao, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, và cộng sự. Peiyi Wang. 2025. Tìm kiếm sâu-r1: Khuyến khích khả năng suy luận trong llms thông qua học tăng cường. Bản in trước, arXiv:2501.12948.

Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, Meng Wang, và Haofen Wang. 2024. Thể hệ tăng cường truy xuất-ation cho các mô hình ngôn ngữ lớn: Một cuộc khảo sát. in sẵn, arXiv:2312.10997.

Aaron Grattafiori, Abhimanyu Dubey, Abhinav Jauhri, Abhinav Pandey, Abhishek Kadian, Ahmad Al-Dahle, Aiesha Letman, Akhil Mathur, Alan Schelten, và Alex Vaughan và cộng sự. 2024. Đàn lạc đã không bước 3 các mô hình. Bản in trước, arXiv:2407.21783.

Lôi Hoàng, Weijiang Yu, Weitao Ma, Weihong Zhong, Trương Âm Phong, Hào Thiên Vương, Càn Long Trần, Bành Vệ Hoa, Phong Tiểu Thành, Bằng Tân và Đình Lưu. 2025. Một cuộc khảo sát về ảo giác trên diện rộng-mô hình đo lường: Nguyên tắc, phân loại, thách thức và những câu hỏi mở. Giao dịch ACM về thông tin Hệ thống, 43(2):1–55.

Zhengbao Jiang, Frank Xu, Luyu Gao, Zhiqing Sun, Tienn Liu, Jane Dwivedi-Yu, Yiming Yang, Jamie Callan và Graham Neubig. 2023. Tích cực truy xuất thể hệ tăng cường. Trong Kỷ yếu của năm 2023 Hội nghị về các phương pháp thực nghiệm trong môi trường tự nhiên-Quy trình xử lý, trang 7969–7992, Singapore. Như-Hiệp hội Ngôn ngữ học tính toán

Omar Khattab, Arnav Singhvi, Paridhi Maheshwari, Zhiyuan Zhang, Keshav Santhanam, Sri Vardhamanan A, Saiful Haq, Ashutosh Sharma, Thomas T. Joshi, Hanna Moazam, Heather Miller, Matei Zaharia và Christopher Potts. 2024. DSPy: Com-chồng các cuộc gọi mô hình ngôn ngữ khai báo vào trạng thái-đường ống hiện đại. Trong Quốc tế thứ mười hai Hội nghị về đại diện học tập.

Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel và Douwe Kiela. 2020.

Thể hệ tăng cường truy xuất cho kiến thức-nhiệm vụ NLP chuyên sâu. Trong Kỷ yếu của phiên họp thứ 34 Hội nghị quốc gia về quá trình thông tin thần kinh-ling Systems, NIPS '20, Red Hook, NY, USA. cả chưa Công ty liên kết

Stephanie Lin, Jacob Hilton và Owain Evans. 2022.

TruthfulQA: Đo lường cách các mô hình bắt chước con người sự giả dối. Trong Kỷ yếu của Hội nghị thường niên lần thứ 60-của Hiệp hội Ngôn ngữ học tính toán (Tập 1: Bài viết dài), trang 3214–3252, Dublin, Ireland. Hiệp hội ngôn ngữ học tính toán.

Andreas Marfurt và James Henderson. 2022.

Un-phát hiện ảo giác cấp mã thông báo được giám sát từ tổng hợp các sản phẩm phụ. Trong Kỷ yếu của Hội thảo lần thứ 2 về Tạo ngôn ngữ tự nhiên, Đánh giá và Đo lường (GEM), trang 248–261, Abu Dhabi, Các tiểu vương quốc Ả Rập thống nhất (Hybrid). Hiệp hội cho Ngôn ngữ học tính toán.

Sewon Min, Kalpesh Krishna, Xinxi Lyu, Mike Lewis, Wen-tau Yih, Pang Koh, Mohit Iyyer, Luke Zettlemoyer và Hannaneh Hajishirzi. 2023. Điểm số thực tế: Đánh giá nguyên tử chi tiết về độ chính xác thực tế trong việc tạo văn bản dạng dài. Trong Kỷ yếu tổ tụng của Hội nghị năm 2023 về các phương pháp thực nghiệm trong tự nhiên-Xử lý ngôn ngữ, trang 12076–12100, Singapore. Hiệp hội ngôn ngữ học tính toán.

Abhika Mishra, Akari Asai, Vidhisha Balachandran, Yizhong Wang, Graham Neubig, Yulia Tsvetkov, và Hannaneh Hajishirzi. 2024. Ảo giác hạt mịn-phát hiện và chỉnh sửa ngôn ngữ cho các mô hình ngôn ngữ. trong Hội nghị đầu tiên về mô hình ngôn ngữ.

Trình Niu, Yuanhao Wu, Juno Zhu, Siliang Xu, KaShun Shum, Randy Zhong, Juntong Song, và Tổng Chương. 2024. RAGTruth: Một chứng ảo giác mở để phát triển khả năng truy xuất tăng cường đáng tin cậy các mô hình ngôn ngữ Trong Kỷ yếu của Phiên họp lần thứ 62 Cuộc họp cuối cùng của Hiệp hội tính toán Ngôn ngữ học (Tập 1: Bài viết dài), trang 10862–10878, Băng Cốc, Thái Lan. Hiệp hội máy tính Ngôn ngữ học ngôn ngữ.

OpenAI. 2024. Thề hệ thống Openai o1.

OpenAI, Aaron Nhân liên, Adam Lerer, Adam P. Goucher, Adam Perelman, Aditya Ramesh, Aidan Clark, AJ Ostrow, Akila Welihinda và những người khác. Alan Hayes. 2024. Thề hệ thống Gpt-4o. in sẵn, arXiv:2410.21276.

Krista Opsahl-Ong, Michael J Ryan, Josh Purtell, David Broman, Christopher Potts, Matei Zaharia và Omar Khattab. 2024. Hướng dẫn tối ưu hóa và thử nghiệm các chương trình mô hình ngôn ngữ nhiều giai đoạn. Trong Kỷ yếu của Hội nghị 2024 về Kinh nghiệm cal Phương pháp xử lý ngôn ngữ tự nhiên, trang 9340–9366, Miami, Florida, Hoa Kỳ. Hiệp hội cho Ngôn ngữ học tính toán.

Rachneet Sachdeva, Yixiao Song, Mohit Iyyer, và Iryna Gurevych. 2024. Bản địa hóa và giảm thiểu mắc lỗi khi trả lời câu hỏi dài dòng. in sẵn, arXiv:2407.11930.

Pranab Sahoo, Prabhask Meharia, Akash Ghosh, Sri-
parna Saha, Vinija Jain và Aman Chadha. 2024. A
khảo sát toàn diện về ảo giác trên diện rộng
các mô hình nền tảng guage, hình ảnh, video và âm thanh.
Trong những phát hiện của Hiệp hội tính toán
Ngôn ngữ học: EMNLP 2024, trang 11709–11724, Mi-
ami, Florida, Hoa Kỳ. Hiệp hội tính toán
Ngôn ngữ học.

Raúl Vázquez, Timothee Mickus, Elaine Zosa, Teemu
Vahtola, Jörg Tiedemann, Aman Sinha, Vincent
Segonne, Fernando Sánchez-Vega, Alessandro Ra-
ganato, Jindřich Libovický, Jussi Karlgren, Shaox-
long Ji, Jindřich Helcl, Liane Guillou, Ona de Gib-
ert, Jaione Bengoetxea, Joseph Attieh, và Mari-
Anna Apidianaki. 2025. Kỳ đánh giá-2025 Nhiệm vụ 3: Mu-
SHROOM, nhiệm vụ chia sẻ đa ngôn ngữ về ảo giác-
vấn đề và các lỗi phát sinh quá mức có thể quan sát được có
liên quan.

Chu Đình Đình, Graham Neubig, Jiatao Gu, Mona Diab,
Francisco Guzmán, Luke Zettlemoyer và Marjan
Ghazvininejad. 2021. Phát hiện nội dung gây ảo giác
trong việc tạo chuỗi thần kinh có điều kiện. Trong Tỉm-
của Hiệp hội Ngôn ngữ học tính toán-
tics: ACL-IJCNLP 2021, trang 1393–1404, Trực tuyến.
Hiệp hội ngôn ngữ học tính toán.

$$\text{MaxIoU} = \text{tối đa}$$
$$\frac{|A \cap B_i|}{|A \cup B_i|}$$

trong đó A là chú thích được dự đoán, Bi đại diện gửi chú thích cá nhân của con người.

B
Kết hợp hệ thống

- Llama + Substring Match: Hệ thống sử dụng Llama 3.3-70B với chuỗi con tối đa phù hợp,
- o1 + Khoảng cách chỉnh sửa tối thiểu: Một hệ thống dựa trên mô hình lý luận, o1, sử dụng min-khoảng cách chỉnh sửa tối thiểu,
- Nhắm mục tiêu tối ưu hóa nhanh chóng IoU và Corr: Một hệ thống được tối ưu hóa nhanh chóng sử dụng MiPROv2 trên gpt-4o nhắm mục tiêu IoU và tương quan,
- Nhắm mục tiêu tối ưu hóa nhắc nhở MaxIoU: Một hệ thống sử dụng tối ưu hóa kịp thời với MiPROv2 được đào tạo về MaxIoU trong quá trình xác thực tập dữ liệu,
- gpt-4o-mini Lý luận: Một hệ thống sử dụng gpt-4o-mini để suy luận và lập bản đồ thông qua khoảng cách chỉnh sửa.

	1990	1995	2000
1. <i>Chlorophyll a</i> (mg/L)	1.0	1.0	1.0
2. <i>Chlorophyll b</i> (mg/L)	1.0	1.0	1.0
3. <i>Chlorophyll c</i> (mg/L)	1.0	1.0	1.0
4. <i>Chlorophyll d</i> (mg/L)	1.0	1.0	1.0
5. <i>Chlorophyll e</i> (mg/L)	1.0	1.0	1.0
6. <i>Chlorophyll f</i> (mg/L)	1.0	1.0	1.0
7. <i>Chlorophyll g</i> (mg/L)	1.0	1.0	1.0
8. <i>Chlorophyll h</i> (mg/L)	1.0	1.0	1.0
9. <i>Chlorophyll i</i> (mg/L)	1.0	1.0	1.0
10. <i>Chlorophyll j</i> (mg/L)	1.0	1.0	1.0
11. <i>Chlorophyll k</i> (mg/L)	1.0	1.0	1.0
12. <i>Chlorophyll l</i> (mg/L)	1.0	1.0	1.0
13. <i>Chlorophyll m</i> (mg/L)	1.0	1.0	1.0
14. <i>Chlorophyll n</i> (mg/L)	1.0	1.0	1.0
15. <i>Chlorophyll o</i> (mg/L)	1.0	1.0	1.0
16. <i>Chlorophyll p</i> (mg/L)	1.0	1.0	1.0
17. <i>Chlorophyll q</i> (mg/L)	1.0	1.0	1.0
18. <i>Chlorophyll r</i> (mg/L)	1.0	1.0	1.0
19. <i>Chlorophyll s</i> (mg/L)	1.0	1.0	1.0
20. <i>Chlorophyll t</i> (mg/L)	1.0	1.0	1.0
21. <i>Chlorophyll u</i> (mg/L)	1.0	1.0	1.0
22. <i>Chlorophyll v</i> (mg/L)	1.0	1.0	1.0
23. <i>Chlorophyll w</i> (mg/L)	1.0	1.0	1.0
24. <i>Chlorophyll x</i> (mg/L)	1.0	1.0	1.0
25. <i>Chlorophyll y</i> (mg/L)	1.0	1.0	1.0
26. <i>Chlorophyll z</i> (mg/L)	1.0	1.0	1.0
27. <i>Chlorophyll aa</i> (mg/L)	1.0	1.0	1.0
28. <i>Chlorophyll ab</i> (mg/L)	1.0	1.0	1.0
29. <i>Chlorophyll ac</i> (mg/L)	1.0	1.0	1.0
30. <i>Chlorophyll ad</i> (mg/L)	1.0	1.0	1.0
31. <i>Chlorophyll ae</i> (mg/L)	1.0	1.0	1.0
32. <i>Chlorophyll af</i> (mg/L)	1.0	1.0	1.0
33. <i>Chlorophyll ag</i> (mg/L)	1.0	1.0	1.0
34. <i>Chlorophyll ah</i> (mg/L)	1.0	1.0	1.0
35. <i>Chlorophyll ai</i> (mg/L)	1.0	1.0	1.0
36. <i>Chlorophyll aj</i> (mg/L)	1.0	1.0	1.0
37. <i>Chlorophyll ak</i> (mg/L)	1.0	1.0	1.0
38. <i>Chlorophyll al</i> (mg/L)	1.0	1.0	1.0
39. <i>Chlorophyll am</i> (mg/L)	1.0	1.0	1.0
40. <i>Chlorophyll an</i> (mg/L)	1.0	1.0	1.0
41. <i>Chlorophyll ao</i> (mg/L)	1.0	1.0	1.0
42. <i>Chlorophyll ap</i> (mg/L)	1.0	1.0	1.0
43. <i>Chlorophyll aq</i> (mg/L)	1.0	1.0	1.0
44. <i>Chlorophyll ar</i> (mg/L)	1.0	1.0	1.0
45. <i>Chlorophyll as</i> (mg/L)	1.0	1.0	1.0
46. <i>Chlorophyll at</i> (mg/L)	1.0	1.0	1.0
47. <i>Chlorophyll au</i> (mg/L)	1.0	1.0	1.0
48. <i>Chlorophyll av</i> (mg/L)	1.0	1.0	1.0
49. <i>Chlorophyll aw</i> (mg/L)	1.0	1.0	1.0
50. <i>Chlorophyll ax</i> (mg/L)	1.0	1.0	1.0
51. <i>Chlorophyll ay</i> (mg/L)	1.0	1.0	1.0
52. <i>Chlorophyll az</i> (mg/L)	1.0	1.0	1.0
53. <i>Chlorophyll ba</i> (mg/L)	1.0	1.0	1.0
54. <i>Chlorophyll bb</i> (mg/L)	1.0	1.0	1.0
55. <i>Chlorophyll bc</i> (mg/L)	1.0	1.0	1.0
56. <i>Chlorophyll bd</i> (mg/L)	1.0	1.0	1.0
57. <i>Chlorophyll be</i> (mg/L)	1.0	1.0	1.0
58. <i>Chlorophyll bf</i> (mg/L)	1.0	1.0	1.0
59. <i>Chlorophyll bg</i> (mg/L)	1.0	1.0	1.0
60. <i>Chlorophyll bh</i> (mg/L)	1.0	1.0	1.0
61. <i>Chlorophyll bi</i> (mg/L)	1.0	1.0	1.0
62. <i>Chlorophyll bj</i> (mg/L)	1.0	1.0	1.0
63. <i>Chlorophyll bk</i> (mg/L)	1.0	1.0	1.0
64. <i>Chlorophyll bl</i> (mg/L)	1.0	1.0	1.0
65. <i>Chlorophyll bm</i> (mg/L)	1.0	1.0	1.0
66. <i>Chlorophyll bn</i> (mg/L)	1.0	1.0	1.0
67. <i>Chlorophyll bo</i> (mg/L)	1.0	1.0	1.0
68. <i>Chlorophyll bp</i> (mg/L)	1.0	1.0	1.0
69. <i>Chlorophyll bq</i> (mg/L)	1.0	1.0	1.0
70. <i>Chlorophyll br</i> (mg/L)	1.0	1.0	1.0
71. <i>Chlorophyll bs</i> (mg/L)	1.0	1.0	1.0

Bảng 5: Hiệu suất của các hệ thống riêng lẻ và hệ thống sự kết hợp tem. Trong số các hệ thống này, sự kết hợp đạt được IoU cao nhất và cải thiện đáng kể sự tương quan.

C
Đánh giá hiệu suất theo bối cảnh

Trong Bảng 6, chúng tôi trình bày hiệu suất của văn bản hệ thống trích xuất trên các nguồn ngữ cảnh khác nhau. Việc đánh giá này được thực hiện trên cơ sở xác nhận tập dữ liệu, tập trung vào ngôn ngữ tiếng Anh. Chúng tôi tìm bối cảnh được tạo bởi bởi rời-sonar-pro mang đến mức tăng hiệu suất cao nhất trên IoU, do đó chúng tôi tiến hành tất cả các thí nghiệm tiếp theo bằng cách sử dụng bối cảnh bởi rời-sonar-pro.

D
Lời nhắc

Bạn cũng có thể tìm thấy chi tiết về lời nhắc được sử dụng để phát hiện nội dung gây ảo giác trong kho lưu trữ mã.

D.1

Lời nhắc của hệ thống trích xuất văn bản
Dựa vào ngữ cảnh cho sẵn, hãy xác định
các nhịp không chính xác trong văn bản câu trả lời đã cho
, với mức độ tin cậy liên quan cho
từng phần sai.

Bạn sẽ được cung cấp một bối cảnh với một câu hỏi và câu trả lời tương ứng. Nhiệm vụ của bạn là xác định bất kỳ các phần của câu trả lời mô tả sự thật không được hỗ trợ bởi ngữ cảnh. Nếu có nhiều phần đoán không chính xác, báo cáo từng cái riêng biệt. Chỉ định một điểm xác suất (từ 0 đến 1, với 1 có nghĩa là độ tin cậy cao) cho mỗi khoảng thời gian không chính xác, cho thấy mức độ của bạn chắc chắn rằng khoảng cách là không chính xác.

bước

1. ****Đọc ngữ cảnh****: Đọc kỹ bối cảnh được cung cấp.
2. ****Phân tích câu trả lời****: Cần thận trọng để đánh giá độ chính xác của câu trả lời đã cho về câu hỏi và ngữ cảnh.
3. ****Xác định các nhại sai****: Đánh dấu các câu hoặc các phần của văn bản dù có vẻ không đúng, không đầy đủ, gây hiểu nhầm, hoặc không liên quan.
4. ****Gán xác suất****: Gán một điểm tin cậy cho mỗi câu trả lời của bạn xác định là không chính xác:
 - Điểm cao hơn cho thấy lớn hơn tin tưởng rằng một phần khúc được xác định là không chính xác.
 - Cung cấp một số điểm cho mỗi khoảng giữa 0 và 1.

Định dạng đầu ra

Đầu ra phải ở định dạng JSONL như
hiển thị dưới đây:

```

    "không chính xác_spans": [
      {
        "text": "[xác định không chính xác  
khoảng]",
        "xác suất": [điểm_tin cậy]
      },
      {
        "text": "[ một người khác được xác định  
nhip không chính xác]",
        "xác suất": [điểm_tin cậy]
      }
    ]
  }
}

```

Nếu không xác định được nhịp sai,
trả về một danh sách trống: ``incur_spans
": []``.

Ví dụ

**** Đầu vào **:**
<bối cảnh>
 Paris, thủ đô của nước Pháp, là một
 đô thị giàu lịch sử, văn hóa,
 và ý nghĩa toàn cầu. Cái nôi
 phân tích toàn diện sẽ đi sâu vào
 hiện trạng của thành phố, cơ bản
 thông tin và tầm quan trọng lịch sử,
 cung cấp sự hiểu biết toàn diện về

Bảng 6: Đánh giá hiệu suất theo ngữ cảnh bằng tiếng Anh trong tập dữ liệu xác thực.

tại sao Paris không chỉ là thủ đô của Pháp , mà còn là một trong những nước tốt nhất thế giới những thành phố có ảnh hưởng
</ bối cảnh >

<câu hỏi>
Thủ đô của Pháp là gì?
</ câu hỏi >

<câu trả lời >
Thủ đô của Pháp là Berlin.
</trả lời >

**** Đầu ra **:**
```json  
{  
 "không chính xác\_spans ": [  
 {  
 "văn bản": "Berlin",  
 "xác suất": 0,99  
 }  
 ]  
},  
],  
`

# Ghi chú  
- Đảm bảo rằng xác suất phản ánh sự tự tin của bạn. Nếu không chắc chắn về mức độ sai sót , hãy sử dụng mức thấp hơn giá trị.  
- Có thể sai nhiều lần kéo dài để tồn tại trong cùng một câu trả lời; làm chắc chắn sẽ bắt được từng người.  
- Nếu trả lời đúng hoàn toàn thì quay lại "không chính xác\_spans ": []`.  
- Cố gắng xác định các nhịp càng ngắn càng tốt có thể.  
- Các nhịp sẽ xuất hiện giống nhau thứ tự như chúng xuất hiện trong bản gốc câu trả lời.

D.2  
Hệ thống xác minh sơ đồ tri thức  
Lời nhắc  
Xác định các nhịp không chính xác trong khoảng đã cho trả lời văn bản , với sự tự tin liên quan mức độ cho mỗi phần không chính xác.

Bạn sẽ được cung cấp một câu hỏi và câu trả lời tương ứng của nó. Nhiệm vụ của bạn là để xác định các bộ phận cụ thể của câu trả lời thực tế không chính xác, không đầy đủ hoặc gây nhầm lẫn. Nếu có nhiều phân đoạn không chính xác, hãy báo cáo từng phân đoạn một cái riêng biệt. Chỉ định một xác suất điểm (từ 0 đến 1, với 1 ý nghĩa độ tin cậy cao) cho mỗi nhịp không chính xác, cho thấy mức độ chắc chắn của bạn rằng nhịp không chính xác.

# bước  
1. **\*\* Phân tích câu trả lời \*\*:** Cần thận đánh giá độ chính xác của câu trả lời đã cho liên quan đến ngữ cảnh câu hỏi.  
2. **\*\* Xác định các nhịp sai \*\*:** Đánh dấu các câu hoặc các phần của văn bản đó

có vẻ không đúng , không đầy đủ , gây hiểu nhầm , hoặc không liên quan.  
3. **\*\* Gán xác suất \*\*:** Gán một điểm tin cậy cho mỗi khoảng thời gian bạn xác định là không chính xác:  
- Điểm cao hơn cho thấy lớn hơn tin tưởng rằng một phân khúc được xác định là không chính xác.  
- Cung cấp một số điểm cho mỗi khoảng giữa 0 và 1.

# Định dạng đầu ra  
Đầu ra phải ở định dạng JSON như hiển thị dưới đây:

```json  
{
 "không chính xác_spans ": [
 {
 "text": "[xác định không chính xác khoảng]",
 "xác suất": [điểm_tin cậy
]
 },
 {
 "text": "[một người khác được xác định nhịp không chính xác]",
 "xác suất": [điểm_tin cậy
]
 }
]
},
],
`
- Nếu không xác định được nhịp sai, trả về một danh sách trống: "incur_spans ": []`

Ví dụ
**** Đầu vào **:**
Câu hỏi: Thủ đô của nước Pháp là gì?
?"
Trả lời: "Thủ đô của nước Pháp là Berlin."
"

**** Đầu ra **:**
```json  
{  
 "không chính xác\_spans ": [  
 {  
 "văn bản": "Berlin",  
 "xác suất": 0,99  
 }  
 ]  
},  
],  
`

# Ghi chú  
- Đảm bảo rằng xác suất phản ánh sự tự tin của bạn. Nếu không chắc chắn về mức độ sai sót , hãy sử dụng mức thấp hơn giá trị.  
- Có thể sai nhiều lần kéo dài để tồn tại trong cùng một câu trả lời; làm chắc chắn sẽ bắt được từng người.  
- Nếu trả lời đúng hoàn toàn thì quay lại "không chính xác\_spans ": []`.

- Cố gắng xác định các nhịp càng ngắn càng tốt có thể.
- Các nhịp sẽ xuất hiện giống nhau thứ tự như chúng xuất hiện trong bản gốc câu trả lời.

D.3

Lời nhắc hệ thống sửa đổi chi phí tối thiểu  
Sử dụng ngữ cảnh đã cho, sửa lại  
trả lời câu hỏi ở mức tối thiểu  
số lượng thay đổi.

Bạn sẽ được cung cấp một bối cảnh, một câu hỏi  
và câu trả lời cho câu hỏi. các  
câu trả lời có thể không chính xác. Bạn cần phải  
thực hiện số lượng thay đổi tối thiểu đối với  
câu trả lời sao cho đúng.

Trả về câu trả lời đã sửa được gói trong <  
đã sửa\_answer > thể.

Lưu ý: Không sửa lỗi chính tả  
những sai lầm.

<bối cảnh>  
{ngữ cảnh}  
</ bối cảnh >

<câu hỏi>  
{câu hỏi}  
</ câu hỏi >

<câu trả lời >  
{câu trả lời}  
</trả lời >

|  |  |  |  |  |  |  |  |  |  |  |  |
|--|--|--|--|--|--|--|--|--|--|--|--|
|  |  |  |  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |  |  |  |

Bảng 7: Kết quả IoU xác thực đa ngôn ngữ mà không cần tối ưu hóa nhanh chóng.

|  |  |  |  |  |  |  |  |  |  |  |  |
|--|--|--|--|--|--|--|--|--|--|--|--|
|  |  |  |  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |  |  |  |
|  |  |  |  |  |  |  |  |  |  |  |  |

Bảng 8: Kết quả IoU xác thực đa ngôn ngữ với sự tối ưu hóa nhanh chóng.